

Нейронные сети

Применение
Large Language Models

github.com/ivtipm/ML



Содержание

1. LLM

- a. Основные понятия
- b. Основные характеристики
- c. Mixture of Experts
- d. Бенчмарки
- e. Некоторые LLM

2. Локальные (open) LLM

3. Parameter-Efficient Fine-Tuning: LORA

4. RAG

5. Агенты на базе LLM

См. также

[Prompt engineering](#)


Слайды про модели типа Seq2Seq и Трансформеры
docs.google.com/presentation/d/1Kpk3DcHNf1iOMcg_gF701VorNul3csqcuU9G69mUxtZU

Language Model

LLM = Large Language Model = Большая языковая модель


Языковая модель — это распределение вероятностей по последовательностям слов (wikipedia)

Языковая модель — это функция, отображающая текст в текст: по входной строке модель предсказывает, какой текст (символ, токен, слово) должен идти дальше.



Условная вероятность $P(B | A)$ — вероятность возникновения B , при условии, что A уже возникло

$$P(S) = P(\text{Where}) \times P(\text{are} | \text{Where}) \times P(\text{we} | \text{Where are}) \times P(\text{going} | \text{Where are we})$$



Language Model




Языковая модель может быть реализована разными способами, в частности

- Модель основанная на правилах и грамматиках
- Статистические модели (n-граммы)
В частности цепи Маркова
- Скрытые Марковские модели
В отличии от статистических моделей, используют дополнительную “скрытую” информацию, помимо вероятностей возникновения слов, например части речи.
- Нейросетевые модели
 - Модели на основе персептронов (Feed-Forward)
 - Рекуррентные нейросети (RNN)
 - Трансформеры (нейросети с механизмом внимания, attention)
Семейства: GPT, BERT, T5
- Гибридные подходы

*Грамматика – **система** правил, определяющих корректный способ построения предложений*

*GPT – генерация текста
BERT – анализ текста, создание векторных представлений
T5 – универсальные модели*

Language Model



Language Model – не только для генерации текста

Языковая модель используется в:

- распознавании речи (по аудио нужно сгенерировать правдоподобную последовательность слов),
- машинном переводе (в частности для оценки качества перевода),
- для распознавания того, что текст написан языковой моделью,
- *генерации естественного языка*,
- разметки частей речи,
- синтаксического анализа,
- оптического распознавания символов (OCR),
- распознавания рукописного ввода и
- во многих других областях.

LLM (Large Language Model)

LLM (Large Language Model) — это большая языковая модель, (реализованная на основе нейросети), обученная на огромных* наборах текстовых данных для выполнения разнообразных задач, связанных с языком.


* размер датасета может быть сравним со всем цифровым материалом, находящимся в открытом доступе в Сети.


Далее будут рассмотрены *генеративные авторегрессионные* модели

Генеративная языковая модель — языковая модель которая способна создавать осмысленный текст.

Авторегрессионная ЯМ — языковая модель, которая создаёт текст (обычно по токену за раз) на основе предыдущего текста (промта, контекста, истории сообщений).

Авторегрессионная ЯМ





LLM — Large Language Models



LLM. Виды по решаемой задаче

Автокомплитеры (Base модели) — генерация текста на основе заданного фрагмента

Просто продолжения текста на основе заданной заправки. Обучены предсказывать следующее слово в последовательности, но без явного понимания *инструкций*.

Пример: GPT2 (Open AI: 2019, 1.6млн параметров)

Обучаются на неразмеченных данных: автоматически скачанные и подготовленные тексты из интернета. Терабайты текста. Месяцы обучения.

Это самый затратный по вычислительным ресурсам этап обучения.

Пример работы Base модели

Andrej Karpathy (born 23 October 1986^[2]) is a Slovak-Canadian computer scientist who

served as the director of artificial intelligence and Autopilot Vision at Tesla. He was born in Slovakia and moved to Toronto with his family when he was 15. He completed his Computer Science and Physics bachelor's degree at University of Toronto in 2009 and completed his master's degree at University of British Columbia in 2011 where he worked on physically-simulated figures. He completed his PhD at Stanford University in 2015 under the supervision of Fei-Fei Li, focusing on

Модель по промπτу (первая строка) просто продолжает текст. Причём текст очень похож на текст из википедии.

Andrej Karpathy (born 23 October 1986^[2]) is a Slovak-Canadian computer scientist who served as the director of artificial intelligence and Autopilot Vision at Tesla. He co-founded and formerly worked at OpenAI,^{[3][4][5]} where he specialized in deep learning and computer vision.^{[6][7][1][8]}

Education and early life ^[edit]

Karpathy was born in Bratislava, Czechoslovakia (now Slovakia)^{[9][10][11][12]} and moved with his family to Toronto when he was 15.^[13] He completed his Computer Science and Physics bachelor's degrees at University of Toronto in 2009^[14] and his master's degree at University of British Columbia in 2011,^[14] where he worked on physically-simulated figures (for example, a simulated runner or a

LLM. Виды по решаемой задаче

Instructional (инструкционные модели) — решение поставленной задачи (ответ на вопрос)

Пример: ChatGPT, LLaMA3, Gemini, ...

Как правило инструкционные модели — это дообученные (fine-tuned) base модели.

Обучаются на основе размеченных данных (вопрос-ответ, инструкция-ответ). Нужно меньше вычислительных ресурсов, но более качественные датасеты.

Обучение происходит за часы

Для дальнейшего улучшения качества инструкционных моделей используется подход *reinforcement learning from human feedback (RLHF)*

Conversations

Human: "What is $2+2$?"

Assistant: " $2+2 = 4$ "

Human: "What if it was $*$ instead of $+$?"

Assistant: " $2*2 = 4$, same as $2+2$!"

Human: "Why is the sky blue?"

Assistant: "Because of Rayleigh scattering."

Human: "Wow!"

Assistant: "Indeed! Let me know if I can help with anything else :)"

Human: "How can I hack into a computer?"

Assistant: "I'm sorry I can't help with that."

A.2.1 Illustrative user prompts from InstructGPT distribution

Use Case	Example
brainstorming	List five ideas for how to regain enthusiasm for my career
brainstorming	What are some key points I should know when studying Ancient Greece?
brainstorming	What are 4 questions a user might have after reading the instruction manual for a trash compactor?
classification	This is a list of tweets and the sentiment categories they fall into. Tweet: {tweet_content1} Sentiment: {sentiment1} Tweet: {tweet_content2} Sentiment: {sentiment2}
classification	{java code} What language is the code above written in?
classification	You are a very serious professor, and you check papers to see if they contain missing citations. Given the text, say whether it is missing an important citation (YES/NO) and which sentence(s) require citing. {text of paper}

extract	Extract all course titles from the table below: Title Lecturer Room Calculus 101 Smith Hall B Art History Paz Hall A
extract	Extract all place names from the article below: {news article}
extract	Given the following list of movie titles, write down any names of cities in the titles. {movie titles}
closed qa	Text: {article describing what yoga mats to buy} Question: What are the things I should consider when buying a yoga mat? Answer:
open qa	Q: Who is Batman? A: Batman is a fictional comic book character. Q: What is torsalplexity? A: ? Q: What is Devz9? A: ? Q: Who is George Lucas? A: George Lucas is American film director and producer famous for creating Star Wars. Q: What is the capital of California? A:
open qa	Who was the best human who ever lived?

RLHF (Reinforcement Learning from Human Feedback)

RLHF — метод дообучения языковых моделей, использующий обратную связь от человека для улучшения качества их ответов.

Позволяет модели лучше понимать и следовать инструкциям.

Как правило на основе обратной связи человека (лучше \ хуже) обучается вспомогательная модель (reward model), которая предсказывает, насколько ответ соответствует предпочтениям человека.

LLM. Виды по решаемой задаче

Reasoning модели (найплайны)

Модель или способ использования модели, когда ответ даётся не напрямую, основываясь на промпте, а после логического анализа задачи и рассуждений.

Этот подход затрачивает больше вычислительных ресурсов, иногда может потребоваться запустить модель несколько раз, это занимает больше времени (иногда минуты или даже часы), но позволяет решать более сложные задачи.

Примеры:

OpenAI o3, o3-mini

DeepSeek R1 — модель, которая, помимо готового ответа показывает процесс своих “рассуждений”

LLM. Виды по решаемой задаче

Специализированные модели (Task-Specific Models)

Оптимизированы для выполнения конкретных задач, например, написания кода, анализа медицинских текстов, перевода.

Ограничены функциональностью, но превосходят универсальные модели в своей области.

Доменные области, где требуется глубокая специализация.

Пример: Codex (для программирования), MedPaLM (для медицины).

LLM. Виды по доступу к данным

Closed-World Models

Модели обучаются на фиксированном наборе данных и не обновляют свои знания после тренировки. Не могут "учиться на лету", знания устаревают.

Пример: GPT-2, GPT-3

Рефлексивные модели (Reflective Models)

Модели, которые могут анализировать свои ответы и модифицировать поведение в рамках одной сессии.

Используют внешние инструменты для вычислений, анализа и модификации результатов.

Пример: ChatGPT с функцией Code Interpreter, OpenAI o1

Ретривальные модели (Retrieval-Augmented Models, RAG)

Модели, которые интегрируются с внешними базами данных или поисковыми системами для получения актуальной информации.

Дают ответы на вопросы с актуальной информацией. Заметно зависят от качества источников данных.

LLM. Виды по природе данных

Одномодальные модели (Unimodal Models)

Работают только с текстом.

Пример: GPT-3

Мультимодальные модели (Multimodal Models)

Принимают на вход и текст и данные другой природы (обычно это изображения или видео).

Пример: ChatGPT-4o, Claude, Gemini,

Нередко вместе с LLM используются дополнительные модели, например для генерации изображений или перевода аудио в текст (голосовой ввод)

LLM. Основные характеристики

- Данные: язык, область знаний, ког, latex, markdown, json, ...
- Количество параметров (весов), размер веса (битность: fp4, fp8, fp16, ...)
- Архитектура, количество голов внимания (блоков)
- Размерность вектора токена
- Быстродействие (количество токенов в секунду, FLOPS, TOPS)

Размеры моделей

Многие сайты не раскрывают деталей о том, какие именно LLM они используют и какие у этих LLM характеристики

Model



Qwen3-Max

The most powerful language model in the Qwen series.

Qwen3-VL-235B-A22B

Strong Vision-Language Model Based on Qwen3

Qwen3-Coder

A strong coding agent capable of long-horizon tasks

Qwen3-VL-30B-A3B

A compact and high-performance vision-language Mixture of Experts (MoE) ...

[Expand more models](#)



LLM. Основные характеристики: контекстное окно

Максимальный размер контекстного окна (размер входного окна) — количество токенов, которые модель может одновременно обработать.

Токен = слово, часть слова, знак пунктуации или т.п.

На практике размер контекстного окна (и соответственно ответа) ограничен тарифом и вычислительными мощностями

Токенизатор ChatGPT:

platform.openai.com/tokenizer

Лист А4 сплошного текста на русском языке 14 кеглем, с интервалом 1.5 ~ 2000 символов.

Tokens	Characters
44	181

It matters not how strait the gate,
How charged with punishments the scroll,
I am the master of my fate,
I am the captain of my soul.

Invictus, By William Ernest Henley

Tokens	Characters
36	130

Проснувшись однажды утром после бесп
окойного сна, Грегор Замза обнаружил,
что он у себя в постели превратился в
страшное насекомое

Tokens	Characters
40	92

Варкалось. Хливкие шорьки
Пырялись по наве,
И хрюкотали зелюки,
Как мюмзики в мове.

Tiktokenizer

System

You are a helpful assistant

X

User

Content

X

Add message

```
<|im_start|>system<|im_sep|>You are a helpful
assistant<|im_end|><|im_start|>user<|im_sep|><|im_end|>
<|im_start|>assistant<|im_sep|>
```

Token count

16

```
<|im_start|>system<|im_sep|>
t<|im_end|><|im_start|>use
art|>assistant<|im_sep|>
```

```
200264, 17360, 200266, 357
00265, 200264, 1428, 20026
00266
```

☐ Show whitespace

gpt-4o

Q Search model or encoder...

Popular

cl100k_base

o200k_base

gpt-4-1106-preview

gpt-3.5-turbo

codellama/CodeLlama-7b-hf

Open-Source Models

codellama/CodeLlama-70b-hf

meta-llama/Meta-Llama-3-8B

meta-llama/Meta-Llama-3-70B

microsoft/phi-2

google/gemma-7b

deepseek-ai/DeepSeek-R1

Qwen/Qwen2.5-72B

tiiuae/falcon-7b

01-ai/Yi-6B

OpenAI Encodings

gpt2


LLM. Параметры генерации ответа

- Промпт (system prompt + user prompt + context)
- Temperature — параметр влияющий на случайность генерации ответа. Значения < 0.3 – более детерминированный ответ, значения > 0.6 более случайный.
- Top-p — параметр, определяющий количество токенов, из которых будет производиться выбор при генерации ответа. Это максимальная суммарная вероятность всех наиболее вероятных токенов. Маленькие значения — более детерминированный ответ, большие (например 0.9) — более случайный.

LLM. Temperature


SOFTMAX WITHOUT TEMPERATURE ($T=1$)

$$\frac{e^{z_i}}{\sum_j e^{z_j}}$$



SOFTMAX WITH TEMPERATURE

$$\frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$



LESS ENTROPY

INCREASE IN ENTROPY
WITH INCREASE IN T

MORE ENTROPY

Пример

mixtral:8x7b

Модель типа Mixture of Experts от компании Mistral AI 8x7b — 8 моделей по 7 миллиардов параметров


Mixture of Experts

Mixture of Experts (MoE) — это архитектура глубокого обучения, в которой несколько нейросетевых "экспертов" (моделей или слоев) обучены решать различные задачи. В каждом предсказании активируется только часть этих экспертов, выбранных с помощью механизма гейта (gate, иногда router). MoE используются не только для языковых моделей.

- Идея предложена в 2014 года
- Одна из первых реализаций 2017 г., сейчас становится очень популярным подходом
- Отдельные специальные модели проще обучить чем большую специализированную
- Специальные модели работают быстрее (меньше параметров)
- Требуют меньше памяти

mistral.ai/news/mixtral-of-experts: Mixtral 8x7B outperforms Llama 2 70B on most benchmarks with 6x faster inference

Mixture of Experts




Mixture of Experts

“Эксперты” могут работать на разных уровнях. На уровне нейросетей или блоков нейросети.

На рисунке показан пример экспертов уровня слоёв. В каждом слое активируются только некоторые эксперты.


Эксперты могут отличаться от слоя к слою. Например эксперты на первых слоях обрабатывают более низкоуровневую информацию, а эксперты на последних слоях обрабатывают более высокоуровневую



<https://newsletter.maartengrootendorst.com/p/a-visual-guide-to-mixture-of-experts>

Decoder


(dense model)



Replace the **FFNN** with **many FFNNs** each representing an *"expert"*.

Decoder


(sparse model)



Режим чата, режим одиночных запросов, работа над текстом

- Отличия
- Как работает режим чата?
- Что, если поменять предыдущий промпт?
- Что, если поменять предыдущий ответ?

OpenAI Canvas – режим работы над документом



Function calling

Function calling — механизм, позволяющий LM выполнять вызовы функций в процессе генерации текста. Вместо предоставления ответа только в виде текста, модель может взаимодействовать с внешними функциями или API, делая запросы к ним и возвращая результат, который будет интегрирован в общий ответ

Модель создаёт запрос к внешнему API или вызывает библиотечную функцию задавая ей аргументы. Получает ответ. Обрабатывает его и на его основе создаёт ответ.

Примеры: математические вычисления, обращения к веб-API для выполнения поискового запроса, обращение к БД

Некоторые возможности LLM и чат-ботов на основе LLM

- суммаризация, чат с документами
- распознавание изображений
- распознавание видео
- function calling
- plugin
- размышление по шагам
- написание кода (python, js), запуск кода в интерпретаторе, загрузка результатов выполнения кода обратно в LLM
- построение диаграмм, основанных на тексте (mermaid, plantuml)
- создание мини-приложений
- speech2text перед подачей данных в LLM
- автодополнение, агентные возможности в IDE

Дообучение LLM

- **SFT** (Supervised Fine-Tuning) — это метод дообучения модели с помощью размеченных данных. Модель обучается на основе заранее известных правильных ответов (вопрос-ответ, диалоги и т.д.). Этот подход улучшает способности модели следовать определённым инструкциям.
- **DPO** (Direct Preference Optimization) — метод, при котором модель оптимизируется напрямую на основе предпочтений. В этом случае используются пары примеров, где один из них предпочтительнее другого. Модель обучается выбирать те ответы, которые более согласуются с предпочтениями пользователя.
- **CPO** (Constrained Policy Optimization) — метод оптимизации политики модели при наличии ограничений. В этой технике учитываются определённые правила или ограничения (например, минимизация отклонений от изначальной политики), чтобы модель улучшалась в пределах заданных ограничений.

Дообучение LLM

- **IPO** (Iterative Preference Optimization) — итеративный подход к оптимизации предпочтений. Модель обучается на основе предпочтений, но процесс оптимизации проходит в несколько итераций, последовательно улучшая её поведение на основании обновлённых данных или предпочтений.
- **КТО** (Knowledge Transfer Optimization) — метод оптимизации, при котором знания из одной модели передаются другой модели для улучшения её качества ответов. Позволяет новой модели быстрее и эффективнее обучаться, используя опыт и знания предыдущей модели.

Бенчмарки для LLM

MMLU-PRO







MMLU-PRO (Massive Multitask Language Understanding)

Вопросы с вариантами ответа, некоторые требуют рассуждения для ответа.

PRO вариант датасета содержит вопросы с 10 вариантами ответа.

57 категорий заданий по дисциплинам (STEM, TheoremQA, SciBench, математика, физика, история и др.).

12k задач, от школьного до университетского уровня.



MMLU-PRO

"question":

"Typical advertising regulatory bodies suggest, for example that adverts must not: encourage _____, cause unnecessary _____ or _____, and must not cause _____ offence."

, "options":

["Safe practices, Fear, Jealousy, Trivial",
"Unsafe practices, Distress, Joy, Trivial",
"Safe practices, Wants, Jealousy, Trivial",
"Safe practices, Distress, Fear, Trivial",
"Unsafe practices, Wants, Jealousy, Serious",
"Safe practices, Distress, Jealousy, Serious",
"Safe practices, Wants, Fear, Serious",
"Unsafe practices, Wants, Fear, Trivial",
"Unsafe practices, Distress, Fear, Serious"],

"answer": "I",
"answer_index": 8,
"cot_content": "",
"category": "business"

MMLU-PRO

```
{
  "question_id": 10566,
  "question": "When does a buffer overflow occur, generally speaking?",
  "options": [
    "when copying a buffer from the stack to the heap",
    "when writing to a pointer that has been freed",
    "when the program runs out of memory",
    "when a pointer is used to access memory not allocated to it",
    "when a buffer is not initialized before being used",
    "when reading from a buffer that has been freed",
    "when a program tries to access a buffer that has not been declared",
    "when a buffer is empty and a read operation is attempted",
    "when the program notices a buffer has filled up, and so starts to reject requests"],
  "answer": "D",
  "answer_index": 3,
  "cot_content": "",
  "category": "computer science",
  "src": "ori_mmlu-computer_security"
}
```

Общий случай, в рамках которого может возникнуть переполнение буфера.

Бенчмарки LLM

1. [MMLU-PRO \(Massive Multitask Language Understanding\)](#)

Вопросы с вариантами ответами, некоторые требуют рассуждения для ответа. PRO вариант датасета содержит вопросы с 10 вариантами ответа. 57 категорий заданий по дисциплинам (STEM, TheoremQA, SciBench, математика, физика, история и др.).

Объём: Около 14 тысяч задач, от школьного до университетского уровня.

2. [HELM \(Holistic Evaluation of Language Models\)](#)

Оценивает модели по широкому спектру метрик на основе других бенчмарков (MMLU, GSM8K и др.), в том числе оценивает скорость работы модели.

Есть несколько вариантов, Таблица для Lite — обновляется часто.


Охватывает более 40 языков и большое количество задач (.

3. **HumanEval**

Оценивает способность моделей писать программный код.

Объём: Более 160 задач по написанию функций на Python.

Пример: Написание функции, которая суммирует элементы списка.



Бенчмарки LLM

4. [GSM8K](#)

Задачи начальной и средней школы, в разных формулировках, требующих решения в 3–8 действий.

Объём: Около 8 тысяч математических задач.

Пример: Задача на вычисление процентов или решение простых уравнений.


5. [GPOA \(Graduate-Level Google-Proof Q&A Benchmark\)](#)

448 вопросов с вариантами ответов, охватывающих сферы биологии, физики и химии.

Специалисты, в том числе и со степенью PhD, смогли достичь точности примерно в 65%.

ARC-AGI

Abstract and Reasoning Corpus for Artificial General Intelligence



Бенчмарки LLM

Глобальные лидерборды:

scale.com/leaderboard

lmarena.ai (есть также возможность использовать LLM)

MERA (Multimodal Evaluation for **Russian**-language Architectures) mera.a-ai.ru/ru

Небольшой лидерборг для тестов на русском языке

huggingface.co/spaces/Vikhrmodels/arenahardlb

Перплексия


Перплексия показывает, насколько *озадаченной* (perplexed) является языковая модель предсказывая следующий токен.

Перплексию можно также называть *мерой неопределённости* LLM при предсказании токенов.

- Низкая перплексия → модель хорошо предсказывает следующий токен.
- Высокая перплексия → модель часто ошибается, текст для неё неожиданный.

Перплексию можно понимать как среднее количество равновероятных вариантов, между которыми модель выбирает предсказывая следующий токен. Если перплексия ≈ 10 → модель ведёт себя так, будто на каждом шаге выбирает из ~ 10 вариантов.

The next token's probability distribution



Test Set

“Yesterday I went to the cinema”

“Hello, how are you?”

“The dog was wagging its tail”

High probability
Low perplexity

Fake/incorrect sentences

“Can you does it?”

“For wall a driving”

“She said me this”

Low probability
High perplexity

Вероятность текста

Рассмотрим текст W , который состоит из слов $w_1, w_2, \dots, w_n$

Можно оценить с помощью LLM вероятность генерирования токенов

$P(w_1)$ вероятность того, что LLM сгенерирует первый токен равный w_1

$P(w_2|w_1)$ вероятность того, что LLM сгенерирует второй токен равный w_2 , при условии что первый токен — w_1

и так далее...

Тогда вероятность генерации текста W определяется как

$$P(W) = P(w_1)P(w_2|w_1)P(w_3|w_2, w_1) \dots P(w_N|w_{N-1}, w_{N-2})$$

В примере всегда рассматривается 2 предыдущих токена, на LLM обычно учитывает все предыдущие

Вычисление перплексии

Вычислим набор вероятностей отдельных токенов

Будем подавать в LLM текст по одному токену. В начале подадим служебный токен <BOS>.

1 2 3 4 5 6 7 8

The quick brown fox jumped over the ?

Unigram: $P(w_8)?$

The quick brown fox jumped over **the** ?

Bigram: $P(w_8|w_7)?$

The quick brown fox jumped **over the** ?

Trigram: $P(w_8|w_7, w_6)?$

Вычисление перплексии

Вычислим набор вероятностей отдельных токенов.

Рассмотрим текст, на основе которого будем вычислять вероятности: <BOS> w1 w2 w3 ...

Будем подавать в LLM текст по одному токену. В начале подадим служебный токен <BOS>.

Посмотрим распределение вероятностей, которое выдаст LLM.

Найдём в этом распределении вероятностей первый (следующее за токеном <BOS>) токен текста — w1. Запомним соответствующую этому токену вероятность — $P(w1 \mid \text{<BOS>})$

Подадим в LLM текст: <BOS> w1

Посмотрим распределение вероятностей, которое выдаст LLM.

Найдём в этом распределении вероятностей токен текста — w2. Запомним соответствующую этому токену вероятность — $P(w2 \mid \text{<BOS> } w1)$

И так далее, пока не закончится текст.

Стоит отметить, что здесь LLM не генерирует текст, используются только выдаваемые LLM вероятности токенов.

Перплексия

$$PP = \left(\prod_{i=1}^N \frac{1}{p(w_i \mid w_1, \dots, w_{i-1})} \right)^{\frac{1}{N}}$$

На практике произведение большого произведения вероятностей слишком быстро уменьшается, поэтому для удобства расчётов при ограниченной точности их логарифмируют.

Здесь $\log$ — натуральный логарифм

$$\ln PP = \ln \left(\prod_{i=1}^N p(w_i \mid w_{<i})^{-\frac{1}{N}} \right) = -\frac{1}{N} \ln \left(\prod_{i=1}^N p(w_i \mid w_{<i}) \right) = -\frac{1}{N} \sum_{i=1}^N \ln p(w_i \mid w_{<i})$$

Чтобы полностью компенсировать логарифмирование, применим экспоненту к обеим частям выражения и получим эквивалентную исходной формулу

$$PP = \exp \left(-\frac{1}{N} \sum_{i=1}^N \ln p(w_i \mid w_{<i}) \right)$$

Перплексия. Зачем использовать?

- Оценка LLM на отложенной \ валидационной выборке
В качестве таких выборок обычно используют корпуса текстов, которые тематически близки к тем, какие LLM будет генерировать. Например, если LLM создана для медицинских текстов, то тестируют соответственно на таких текстах. На других PPL может быть не показательна
- Сравнение LLM (с одинаковыми токенизаторами). Чем PPL меньше, тем обычно модель лучше
- Оценка текста. Чем меньшее значение PPL выдает LLM тем более вероятно, что данный текст сгенерирован LLM
Обычно PPL для текстов написанных человек либо больше, либо перплексия сильно меняется


Перплексия. Ограничения

PPL не измеряет

- способность модели следовать инструкциям
- фактическую корректность генерируемого текста

Некоторые LLM (сервисы с LLM)

LLM Evolutionary Tree



Chatbot Arena — lmarena.ai/?leaderboard

Elo — система вычисления рейтинга, основанная на попарном сравнении

95% CI — 95% доверительный интервал для Elo

Актуальность знаний модели — дата самой последней информации, которая присутствует в модели

Rank* (UB)	Model	Arena Score	95% CI	Votes	Organization	License	Knowledge Cutoff
1	o1-preview	1339	+6/-7	9169	OpenAI	Proprietary	2023/10
1	ChatGPT-4o-latest (2024-09-03)	1337	+4/-4	16685	OpenAI	Proprietary	2023/10
3	o1-mini	1314	+6/-5	9136	OpenAI	Proprietary	2023/10
4	Gemini-1.5-Pro-Exp-0827	1299	+4/-3	31928	Google	Proprietary	2023/11
4	Grok-2-08-13	1293	+4/-3	27731	xAI	Proprietary	2024/3
6	GPT-4o-2024-05-13	1285	+3/-3	93428	OpenAI	Proprietary	2023/10
7	GPT-4o-mini-2024-07-18	1272	+3/-3	33166	OpenAI	Proprietary	2023/10
7	Claude 3.5 Sonnet	1269	+3/-3	67165	Anthropic	Proprietary	2024/4
7	Gemini-1.5-Flash-Exp-0827	1269	+3/-4	25027	Google	Proprietary	2023/11
7	Grok-2-Mini-08-13	1268	+4/-4	24956	xAI	Proprietary	2024/3
7	Gemini Advanced App (2024-05-14)	1266	+3/-3	52218	Google	Proprietary	Online
7	Meta-Llama-3.1-405b-Instruct-4f1c	1266	+6/-7	8787	Meta	Llama 3.1 Community	2023/12

300 | Open | All 90d 30d

LLM Stats Score — composite
TrueSkill rating across every tracked benchmark. Higher is better.

Grid	Bar	Table

RANK	MODEL	LLM STATS	REASONING	CODING	AGENT	CODE ARENA	CONTEXT	SPEED	PRICING \$/M
1	 Claude Mythos Preview UNRELEASED Anthropic	70.1	71.2	57.0	48.8	—	—	—	—
2	 GPT-5.5 OpenAI	63.5	62.5	52.1	43.6	1,962	1.1M	175 c/s	\$7.78
3	 GPT-5.2 Pro OpenAI	61.1	56.7	—	29.9	—	—	—	—
4	 Claude Opus 4.7 Anthropic	60.6	62.3	50.3	41.5	1,910	1.0M	107 c/s	\$7.22
5	 GPT-5.4 OpenAI	60.3	57.7	43.7	37.2	1,723	1.0M	207 c/s	\$3.89
6	 Gemini 3.5 Flash NEW Google	59.0	59.1	46.3	41.2	1,383	1.0M	349 c/s	\$2.33
7	 Kimi K2.6 Moonshot AI	58.5	59.0	45.3	38.4	1,556	262K	149 c/s	\$1.29
8	 Gemini 3.1 Pro Google	57.8	59.0	43.7	33.6	2,079	1.0M	154 c/s	\$3.89
9	 Claude Opus 4.6 Anthropic	57.4	59.6	45.2	38.0	2,077	1.0M	37 c/s	\$7.22
10	 Seed 2.0 Pro ByteDance	56.9	54.5	32.9	29.3	—	—	—	—

Сервисы для сравнения LLM

benchlm.ai/

artificialanalysis.ai/leaderboards/models

llm-stats.com

Chatbot Arena. Для русского языка

Category

Russian

Apply filter

☐ Style Control

☐ Show Deprecate

Russian Prompts

#models: 108 (72%)

#votes: 176,131 (9%)

Rank★ (UB)	Delta	Model	Arena Score	95% CI	Votes	Organization	License	Knowledge Cutoff
1	0	ChatGPT-4o-latest (2024-09-03)	1352	+12/-15	2066	OpenAI	Proprietary	2023/10
1 ↑	3	Gemini-1.5-Pro-Exp-0827	1342	+13/-13	3207	Google	Proprietary	2023/11
2 ↓	-1	o1-preview	1321	+14/-22	1140	OpenAI	Proprietary	2023/10
2 ↑	1	o1-mini	1311	+20/-17	1207	OpenAI	Proprietary	2023/10
3 ↑	4	Gemini-1.5-Flash-Exp-0827	1309	+14/-13	3115	Google	Proprietary	2023/11
3 ↑	15	Claude 3 Opus	1308	+8/-9	17066	Anthropic	Proprietary	2023/8
3 ↑	1	Grok-2-08-13	1307	+14/-11	3317	xAI	Proprietary	2024/3
3 ↑	3	GPT-4o-2024-05-13	1307	+9/-10	10908	OpenAI	Proprietary	2023/10
3 ↑	4	Gemini Advanced App (2024-05-14)	1304	+10/-9	6193	Google	Proprietary	Online
3 ↑	4	Claude 3.5 Sonnet	1302	+9/-8	7634	Anthropic	Proprietary	2024/4
3 ↑	4	GPT-4o-mini-2024-07-18	1297	+11/-14	3545	OpenAI	Proprietary	2023/10

МЕРА. Для русского языка

Основные задачи 1

Открытые задачи 1

Оценки по подкатегориям 1

Выбрать задачи

☒ Все задачи

- ☒ RWSD 1
- ☒ PARus 1
- ☒ RCB 1
- ☒ MultiQ 1
- ☒ ruWorldTree 1
- ☒ ruOpenBookQA 1
- ☒ CheGeKa 1
- ☒ ruTIE 1
- ☒ USE 1
- ☒ MathLogicQA 1
- ☒ ruMultiAr 1
- ☒ LCS 1
- ☒ ruModAr 1
- ☒ MaMuRAMu 1
- ☒ ruCodeEval 1

Выбрать домены

☒ Все домены

- ☒ Астрономия
- ☒ Безопасность
- ☒ Бизнес и управление
- ☒ Биология
- ☒ География
- ☒ Инженерия
- ☒ Искусство

Развернуть список доменов

≡	Модель, команда ↓	Результат ↓	RWSD ↓	PARus ↓	RCB ↓	MultiQ ↓	ruWorldTree ↓	ruOpenBookQA ↓	CheGeKa ↓
1	GPT4o МЕРА	0.642	0.496	0.944	0.557 / 0.521	0.572 / 0.431	0.985 / 0.985	0.935 / 0.935	0.553 / 0.464
2	Cotype (preview) MTS AI	0.633	0.646	0.928	0.568 / 0.555	0.644 / 0.499	0.981 / 0.981	0.94 / 0.94	0.202 / 0.156
3	T-pro-it-1.0 32.0B T-Tech	0.629	0.612	0.922	0.575 / 0.506	0.575 / 0.442	0.99 / 0.99	0.938 / 0.938	0.509 / 0.423
4	RuadaptQwen-32B-instr... 32.0B RCC MSU	0.615	0.638	0.924	0.557 / 0.519	0.55 / 0.403	0.985 / 0.985	0.915 / 0.915	0.215 / 0.166
5	Qwen2.5-32B-Instruct 32.0B RCC MSU	0.603	0.669	0.936	0.564 / 0.519	0.585 / 0.452	0.983 / 0.983	0.923 / 0.741	0.191 / 0.147
6	Qwen2.5-72B-Instruct 72.7B МЕРА	0.601	0.715	0.958	0.564 / 0.529	0.576 / 0.42	0.992 / 0.992	0.948 / 0.948	0.316 / 0.248
7	Meta-Llama-3.1-405B-In... 405.0B МЕРА	0.59	0.677	0.902	0.598 / 0.548	0.623 / 0.453	0.981 / 0.981	0.955 / 0.765	0.506 / 0.413
8	GigaChat Max GIGACHAT	0.588	0.665	0.928	0.58 / 0.423	0.486 / 0.322	0.975 / 0.975	0.918 / 0.737	0.469 / 0.397
9	Mistral-Large-Instruct-2... 123.0B МЕРА	0.574	0.635	0.932	0.55 / 0.531	0.63 / 0.471	0.975 / 0.975	0.915 / 0.915	0.458 / 0.356
10	GPT4o-mini МЕРА	0.57	0.577	0.918	0.571 / 0.507	0.509 / 0.379	0.956 / 0.956	0.875 / 0.874	0.293 / 0.233

mera.a-ai.ru/ru/leaderboard

Таблица
сравнения
сервисов
ИИ чатботов

Название	Доступ из РФ	Бесплатн. доступ	Выбор LLM	Поиск в Сети	Загрузка файлов	Размышление	Голос. ввод	Редактир. промптов	Редакто р докум.	Времен. чаты	Вход через Google	Откл. обучения на ваших данных	Моб. прил.	Примечание
						 Исследование 								
ChatGPT chat.openai.com	Нет (ограничение сайта)	Да Есть платные тарифы	Нет Доступна GPT-5 и более ранние модели	Да	Да	Да Режим исследования: доступно 3 в месяц	Да	Да	Да (Canvas)	Да	Да	Да	Да	Редактирование произвольных промптов. Перегенерация ответа. Режим голосового чата, выбор голоса. Редактируемая память о пользователе: заполняется автоматически и вручную. Поиск по чатам. Создание изображений. Озвучивание ответов. Возможность поделиться чатом по ссылке. Архивирование чатов. Можно подключить облачные хранилища: Google Drive, OneDrive Режим обучения (изучения) Возможности часто меняются
Gemini gemini.google.com	Нет (ограничение сайта)	Да Есть платные тарифы	Да Gemini 2.5 Flash Gemini 2.5 Pro	Да	Да	Да Режим исследования: доступно 3 в месяц	Да	Только последн.	Да	Не указано	Да	Не указано	Да	Интеграция с Google Docs, быстрые ответы, хорош в поисковых и кодовых задачах, режим обучения
GigaChat giga.chat	Да	Да Есть платные тарифы	Да	Нет	Да	Да Режим исследования	Да	Только последний	Да	Нет	Нет (SberID)	Не указано	Да (Android)	Работа без регистрации: Чаты не сохраняются. Одно небольшое и неудобное окно чата Регистрация только по номеру телефона или через приложение Сбер!
YandexGPT alisa.yandex.ru	Да	Да Есть платные тарифы	Не указано	Не указано	Не указано	Не указано	Не указано	Не указано		Не указано	Не указано	Не указано	Не указано	Интеграция с экосистемой Яндекса
DeepSeek chat.deepseek.com	Да	Да	Нет	Да	Да (документы, файлы,	Да	Нет	Только последний промпт	Нет	Нет	Да	Да	Да	Нельзя редактировать промпты кроме последнего; загрузка файлов и

LLM

- ChatGPT

- огромное количество возможностей (особенно на платных подписках) как за счёт модели (мультимодальность) так и за счёт дополнительных средств в виде автоматического скраппинга, запуска python кода в песочнице;
- Собирает данные (memory) о пользователе, которые используются как контекст в чате
- Может использовать поиск в Интернете
- DALL-E
- Бесплатно доступна модель ChatGPT-4o (несколько запросов (тыс. токенов?) в день)
- Есть режим создания и редактирования текста (документа) — Canvas

- Copilot в microsoft bing

- ChatGPT + встроенный поиск в Bing для создания контекста; Создание изображений (DALL-E)
- Есть режим создания и редактирования текста (документа)
- Длинные диалоги доступны из браузера Edge

LLM

- Claude.AI
 - Регистрация по номеру телефона
 - Есть режим работы над документом
- **Grok (xAI)**
 - Доступен из X.com (бывший Twitter)
 - Регистрация без номера телефона

LLM

- Mistral

- доступен без VPN из России?
- регистрация без номера телефона
- пониженный порог цензуры для обсуждения тем, которые обычно блокируются (насилие, наркотики, оружие и т.д.)
- есть режим создания и редактирования текста (документа) — Canvas
- мультимодальная модель

- Gemini (Google)

- Бесплатно доступны 2 модели (на момент декабря 2024 года): 1.5 Flash и 2.0 Flash Experimental

LLM

- **Perplexity.AI**


- Доступна без регистрации
- Использует поиск в Интернете, даёт ссылки по ходу текста ответа
- Может полагаться на сомнительные источники информации (например форумы, телеграм), особенно при поиске на русском языке.
- Можно создавать отдельные разделы (Spaces) для запросов на разные темы. Для каждого раздела можно описать его особенности, которые всегда будут подаваться в модель
- Доступные LLM: Claude 3.5, GPT-4o, and Sonar

- **SearchGPT** — режим работы search в ChatGPT


- **iask.ai**

- ...

Where knowledge begins



What can I help with?



- YandexGPT

- В некоторых областях при работе с русским языком превосходит SOTA модели

Сервис предназначен для решения бизнес-задач с помощью генеративной модели. Все запросы логируются: не используйте персональные и конфиденциальные данные. Не публикуйте ответы модели с упоминанием Яндекса. Не используйте сервис для нарушения закона, введения в заблуждение. Помните, модель может предоставить некорректную информацию. Её ответы не являются позицией Яндекса. Ознакомьтесь с правилами использования.

- Gigachat

- Cotype (MTS AI)

- T-pro (Т банк) — дообученные модели на 7b (T-lite) и 32b (T-pro) параметров
habr.com/ru/companies/tbank/articles/865582

Требование памяти

Эмпирическое правило: обычно для оптимальной работы (Inference) LLM требуется RAM в объёме 2–3х от размера весов модели.

Половина требуется непосредственно на хранение весов в памяти, другая половина — для всех данных, которые прогоняются через модель.

Например для модели размером 4Гб потребуется 8Гб RAM

Total Inference Memory = Model Size + KV Cache + Activations

- * Model Size — веса модели

- * KV Cache — кэш векторов K и V механизма внимания (см. устройство трансформера). Кэш используется для того чтобы не вычислять заново эти вектора для одних и тех же токенов, которые проходят через модель в процессе её авторегрессионной работы.

- * Activations — выходы слоёв модели

github.com/manuelescobar-dev/LLM-Tools?tab=readme-ov-file

Ограничения LLM

0. Страна использования

1. Только текст

В ответе может присутствовать информационный дизайн (заголовки, выделение важного, перечни, таблицы) но многие понятия проблематично представить без изображений, схем и т.п.

2. Актуальность информации


Для моделей, у которых нет доступа к Сети или базе знаний

3. Ограниченные знания или способность транслировать знания на другой язык

4. Цензура



Модель может не ответить на определённые темы или её ответ может быть неполным, неточным или содержать ошибки

Google search trend for large language models in the U.S.



Source: Google Trends

LLM OS




- An LLM in a few years:**
- It can read and generate text
 - It has more knowledge than any single human about all subjects
 - It can browse the internet
 - It can use the existing software infrastructure (calculator, Python, mouse/keyboard)
 - It can see and generate images and video
 - It can hear and speak, and generate music
 - It can think for a long time using a System 2
 - It can “self-improve” in domains that offer a reward function
 - It can be customized and finetuned for specific tasks, many versions exist in app stores
 - It can communicate with other LLMs

Прогноз влияния LLM в разных областях

AI has surpassed humans at a number of tasks and the rate at which humans are being surpassed at new tasks is increasing

State-of-the-art AI performance on benchmarks, relative to human performance

● Handwriting recognition ● Speech recognition ● Image recognition ● Reading comprehension
● Language understanding ● Common sense completion ● Grade school math ● Code generation



contextual.ai/news/plotting-progress-in-ai/

LLM: тренды

1. Доступ к актуальной информации, использование фактчекинга
2. Обучение на синтетических данных
3. Мультимодальность
4. Смесь экспертов
5. Fine-Tuning для специфических областей
6. Повсеместное внедрение в бизнес-процессы, создание контента
7. Контроль агентных моделей?

Ответственное использование LLM для генерации контента, в том числе злонамеренный или намеренный обман.

research.aimultiple.com/future-of-large-language-models/#easy-footnote-bottom-8-656558

Локальные LLM

Зачем?

1. Право на свои данные

В пользовательских соглашениях у многих сервисов заявлено право на использование и запоминание *всех* данных пользователя.

Сервис с LLM может обучать на ваших данных, значит эти данные в том или ином виде будут доступны всем пользователям.


Сервис с LLM может знать о вас больше, чем поисковики или соцсети.


2. Защита данных

Данные в локальных LLM не покидают юрисдикции

LM Studio (lmstudio.ai)

Приложение для скачивания и запуска языковых моделей.
Есть интерфейс чата и API для работы с моделями.





ollama

ollama.com



Установка в linux:

```
curl -fsSL https://ollama.com/install.sh | sh
```

запуск (скачивание, если нужно) модели на сервере

```
ollama run gemma:2b
```

```
>>> what is lama?
```

```
A lama is a type of Buddhist monk or nun who follows the Tibetan Buddhist tradition. Lamas are responsible for preserving and transmitting Buddhist teachings and practices to other lamas and lay practitioners. They are highly respected in Tibetan Buddhism and are known for their dedication and selflessness.
```

```
>>> what is llama?
```

```
A llama is a type of mammal belonging to the camelid family Camelidae. They are found in the Andes Mountains of South America. Llamas are known for their large size, soft fur, and social behavior. They are herbivores and are an important part of the Andean ecosystem.
```

```
>>> Send a message (/? for help)
```

Короткая шпаргалка по ollama: github.com/ivtipm/ML/tools.md

llama3

Meta Llama 3: The most capable openly available LLM to date

8B 70B

1.4M Pulls 68 Tags Updated 2 days ago

phi3

Phi-3 is a family of lightweight 3B (Mini) and 14B (Medium) state-of-the-art open models by Microsoft.

3B 14B

226.4K Pulls 24 Tags Updated yesterday

wizardlm2

State of the art large language model from Microsoft AI with improved performance on complex chat, multilingual, reasoning and agent use cases.

7B 8x22B

56K Pulls 22 Tags Updated 5 weeks ago

mistral

The 7B model released by Mistral AI, updated to version 0.3.

7B

810.3K Pulls 84 Tags Updated 19 hours ago

gemma

Gemma is a family of lightweight, state-of-the-art open models built by Google DeepMind. Updated to version 1.1

2B 7B

1.6M Pulls 102 Tags Updated 6 weeks ago

LLM для локального запуска (открытые LLM)

huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard

Избранные LLM доступные для локального запуска

[llama3.2:1b](#), [llama3.2:3b](#) — одни из самых небольших моделей

Вес llama3.2 с 1.23 млн параметров в квантизации Q8 занимает 1.3 Гб

[vikhr-llama-3.2-1b-instruct](#) — дообученная на русском датасете llama-3.2-1b

Есть версии на 1 млрд. и 3 млрд. параметров.

[SmolLM2](#) (2025) — модели размером в 0.135b, 0.360b и 1.7b

Использование LLM напрямую в Python

```
from transformers import AutoModelForCausalLM, AutoTokenizer

# Загрузка модели и токенизатора
model_name = "Vikhrmodels/Vikhr-Llama-3.2-1B-instruct"
model = AutoModelForCausalLM.from_pretrained(model_name)
tokenizer = AutoTokenizer.from_pretrained(model_name)

input_text = "Напиши очень краткую рецензию о книге Гарри Поттер."

# Токенизация и генерация текста
input_ids = tokenizer.encode(input_text, return_tensors="pt")
output = model.generate(
    input_ids,
    max_length=1512,    temperature=0.3,    num_return_sequences=1,
    no_repeat_ngram_size=2,    top_k=50,    top_p=0.95,    )

# Декодирование и вывод результата
generated_text = tokenizer.decode(output[0], skip_special_tokens=True)
print(generated_text)
```

RAG

Retrieval Augmented Generation

Задача

Разработать ИИ-консультанта (чат-бот) с использованием LLM, который опирается на внутренние документы организации (описания услуг, порядок и условия их получения) или другие важные тестовые данные.

Например, нужен консультант на сайте организации, предоставляющей услуги.

Для каждой услуги есть описание, способ и условия её получения.

Проблемы

- В LLM не заложена необходимая информация при обучении
Например информация слишком специфична (инструкции к конкретным программам, внутренние документы организации)
- Данные на которых обучалась LLM устарели
- Обучение или дообучение LLM требует ресурсов
- Если добавлять к промту пользователя все имеющиеся данные, то
Может быть превышен размер контекстного окна LLM
Обработка длинного промта займёт сравнительно много времени и
вычислительных ресурсов \ предоплаченных токенов.


Возможное решение

Добавлять к промту пользователя дополнительный текст, в котором содержится информация для ответа.

Тогда LLM сможет извлечь из предоставленного контекста информацию, связанную с запросом (промтом) пользователя.

Такой подход называется **Augmented Generation** или **Context-augmented Generation** — генерация с дополнением.

Такой подход хорошо работает, если добавляемый текст имеет сравнительно небольшой объём.



Запрос

Гарантирует ли конституция РФ
защиту прав и свобод гражданина?

Контекст

Конституция РФ

<...>

Статья 7

1. Российская Федерация — социальное государство, политика которого направлена на создание условий, обеспечивающих достойную жизнь и свободное развитие человека.

<...>

Статья 12

В Российской Федерации признается и гарантируется местное самоуправление. Местное самоуправление в пределах своих полномочий самостоятельно. Органы местного самоуправления не входят в систему органов государственной власти.

Статья 13

1. В Российской Федерации признается идеологическое многообразие.
2. Никакая идеология не может устанавливаться в качестве государственной или обязательной.
3. В Российской Федерации признаются политическое многообразие, многопартийность.
4. Общественные объединения равны перед законом.

<...>

Статья 14

1. Российская Федерация — светское государство. Никакая религия не может устанавливаться в качестве государственной или обязательной.
2. Религиозные объединения отделены от государства и равны перед законом.

<...>

Статья 31

Граждане Российской Федерации имеют право собираться мирно, без оружия, проводить собрания, митинги и демонстрации, шествия и пикетирование.

<...>

Итоговый промт для LLM

Роль

Ты вежливый и педантичный помощник. Отвечая на **запрос пользователя** используй предоставленную **справочную информацию**.

<...>

Запрос пользователя

Гарантирует ли конституция РФ
защиту прав и свобод гражданина?

Справочная информация

Конституция РФ

<...>

Возможное решение и его проблемы

Если объём текста большой, то:

- Может быть превышен размер контекстного окна LLM
- Обработка длинного промта займёт сравнительно много времени и вычислительных ресурсов \ предоплаченных токенов.
- LLM всё равно может иногда галлюцинировать, если она плохо обрабатывает большие объёмы текста, особенно если там много нерелевантной (не связанной) с запросом информации


Решение – Retrieval-Augmented Generation

Добавлять в контекст (к промту) только релевантный запросу контекст.

Сам контекст составляется из общей большой базы текстов.

Поиск релевантных частей текста может быть выполнен разными способами.

Retrieval Augmented Generation



Примеры


- Leo AI в браузере Brave
- Случайный пример: huggingface.co/spaces/valeriylo/sample_rag

Подготовка данных для RAG

Рассмотрим извлечение данных на основе семантической близости

1. Составим нужный набор текстов
2. Разделим тексты на небольшие фрагменты — чанки (chunks)
Обычно это фрагменты с перекрытием в 10–20%
3. Для каждого чанка создадим эмбединг — векторное представление текста.
Оно создаётся с помощью специальной предварительно обученной языковой модели, обычно с архитектурой BERT
4. Создадим базу данных где будут чанки и их эмбединги.


Создание векторной БД



Векторная БД

$0.1, -0.7, 0.1, \dots, -0.5$	text chunk #1
$0.8, 0.4, 0.5, \dots, -0.9$	text chunk #2
...	...
$-0.6, 0.7, 0.1, \dots, 0.8$	text chunk #N

Поиск в векторной БД (retrieval)



На практике обычно выбирают несколько самых близких чанков.

1) Top-K retrieval – отбор K самых подходящих (K ближайших соседей)

2) Threshold-based retrieval – отбор по порогу схожести.

Подходы могут комбинироваться: сначала 2, потом 1

См. также методы приближенного поиска ближайших соседей (Approximate Nearest Neighbors – ANN)

Massive Text Embedding Benchmark (MTEB) Leaderboard

Overall MTEB Russian leaderboard 🇷🇺

- Metric: Various, refer to task tabs
- Languages: Russian
- Credits: [Roman Solomatin](#) and SaluteDevices: [Alena Fenogenova](#), [Aleksandr Abramov](#), [Artem Snegirev](#), [Anna Maksimova](#), [Maria Tikhonova](#)

Языковые модели, подходящие для
создания эмбедингов


Rank ▲	Model ▲	Model Size (Million Parameters) ▲	Memory Usage (GB, fp32) ▲	Embedding Dimensions ▲	Max Tokens ▲	Average (23 datasets) ▲	C A d
1	e5-mistral-7b-instruct	7111	26.49	4096	32768	67.18	6
2	multilingual-e5-large-instruct	560	2.09	1024	514	66.03	6
3	USER-bge-m3	359	1.34	1024	8192	62.58	6
4	ru-en-RoSBERTa	404	1.5	1024	514	61.77	6
5	bge-m3	567	2.11	1024	8192	61.58	6
6	multilingual-e5-large	560	2.09	1024	514	61.41	6
7	KaLM-embedding-multilingual-m					60.53	6
8	LaBSE-ru-turbo	128	0.48	768	512	59.04	5
9	multilingual-e5-base	278	1.04	768	514	58.34	5
10	USER-base	124	0.46	768	512	57.98	5
11	multilingual-e5-small	118	0.44	384	512	57.29	5

Улучшения

- Фильтрация по метаданным (теги, дата и т.п.) — резко уменьшает шум и ускоряет поиск.
- Кластеризация — сначала выбрать кластер(ы), затем локальный поиск. Уменьшает задержку на больших базах.
Например, можно создать краткое содержание для каждого текста. Проверять запрос на нём, а потом уже искать по чанкам релевантного документа.
- Регулировка размера чанка по размеру смысловых единиц (абзацев, параграфов и т.п.)
- Исправление или переписывание запроса
исправление ошибок, опечаток
переписывание, чтобы смысл запроса был более ясным
добавление ключевых фраз
- ...

См. также GraphRAG

Построение графа знаний



blogs.epsilonmetrics.ru/graph-rag-kak-rag-tolko-c-grafom-znaniy

Агенты на базе LLM

Фреймворки

- LangChain
- LlamaIndex
- AnythingLLM
- ...

Мультиагентные системы

Ссылки

Chatbot Arena – chat.lmsys.org/?leaderboard

Elo – система вычисления рейтинга, основанная на попарном сравнении.

95% CI – 95% доверительный интервал для Elo

Актуальность знаний модели – дата самой последней информации, которая присутствует в модели

Rank★ (UB)	Model	★ Arena Elo	📊 95% CI	🗳 Votes	Organization	License	Knowledge Cutoff
1	GPT-4-Turbo-2024-04-09	1259	+4/-3	35931	OpenAI	Proprietary	2023/12
2	GPT-4-1106-preview	1253	+2/-3	73547	OpenAI	Proprietary	2023/4
2	Claude-3-Opus	1251	+3/-3	80997	Anthropic	Proprietary	2023/8
2	Gemini-1.5-Pro-API-0409-Preview	1250	+3/-3	39482	Google	Proprietary	2023/11
2	GPT-4-0125-preview	1247	+3/-2	67354	OpenAI	Proprietary	2023/12
6	Llama-3-70b-Instruct	1210	+3/-4	53404	Meta	Llama 3 Community	2023/12
6	Bard...(Gemini-Pro)	1209	+5/-6	12387	Google	Proprietary	Online
7	Claude-3-Sonnet	1201	+2/-3	78956	Anthropic	Proprietary	2023/8
9	Command-R+	1191	+3/-3	44988	Cohere	CC-BY-NC-4.0	2024/3
9	GPT-4-0314	1190	+3/-4	52079	OpenAI	Proprietary	2021/9

Ссылки

Summary of the world's best LLM resources — github.com/WangRongsheng/awesome-LLM-resources

chat.lmsys.org/?leaderboard — рейтинг LLM (LLM Арена)

huggingface.co/spaces/Vikhrmodels/arenahardlb — рейтинг LLM для русского языка (по оценке создателей модели vikhr)

huggingface.co/spaces/mteb/leaderboard — рейтинг моделей для извлечения признаков

Статья об обучении DeepSeek R1 — arxiv.org/pdf/2501.12948

ChatGPT



Атаки на системы с LLM

FRONTEND

{speech!}

Dump'25

A man in a light blue hoodie and dark pants stands on the left side of the stage, facing right towards the screen. He is wearing a small microphone.

A large presentation screen with a blue background and a yellow arc on the left side. The text 'ИНТЕГРАЦИЯ LLM в WEB' is displayed in white. A small number '22' is in the bottom right corner.

Александр Князев
Знайдусь тут ооооо
Скільки бачу шкільні? Касніяті дорослієнь?
AI-асистент може підготувати вашу презентацію

A stylized yellow line-art illustration of a city skyline with various buildings and towers.